딥러닝을 함께 공부해보세~
영차영차 2일차

3. 신경망

3-1. 퍼셉트론에서 신경망으로..

3-1. 퍼셉트론에서 신경망으로..

입력층, 은닉층, 출력층.. (그냥 용어만 추가)

그림 2-13 XOR의 퍼셉트론

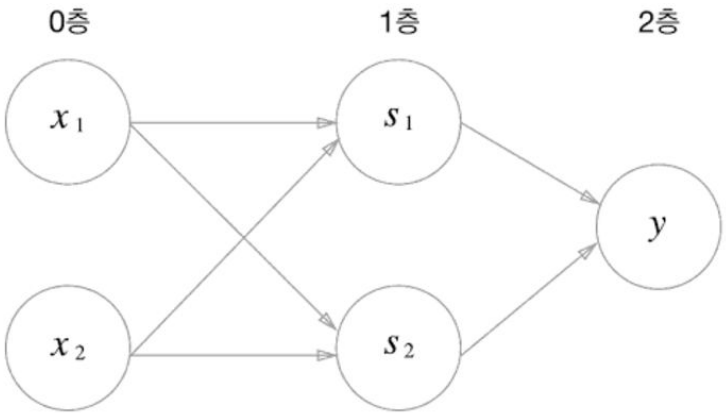

그림 3-1 신경망의 예

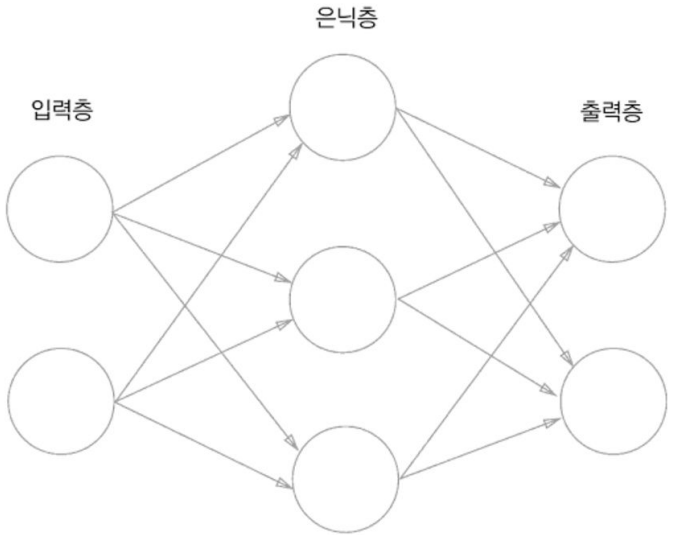

3-1. 퍼셉트론에서 신경망으로..

퍼셉트론 복습

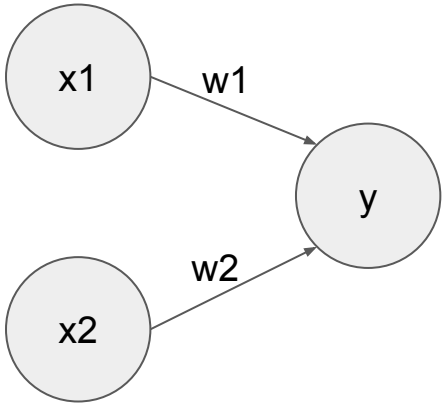

$$y = \begin{cases} 0 & (w1x1 + w2x2 <= \theta) \\ 1 & (w1x1 + w2x2 > \theta) \end{cases}$$

$$y = \begin{cases} 0 & (w1x1 + w2x2 + b <= 0) \\ 1 & (w1x1 + w2x2 + b > 0) \end{cases}$$

3-1. 퍼셉트론에서 신경망으로..

퍼셉트론 복습

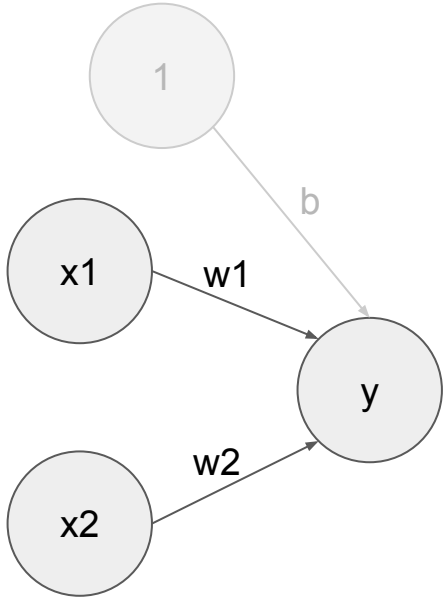

$$y = \begin{cases} 0 & (w1x1 + w2x2 + \mathbf{b} \leq 0) \\ 1 & (w1x1 + w2x2 + \mathbf{b} > 0) \end{cases}$$

```python
def AND(x1, x2):
    x = np.array([x1, x2])
    w = np.array([0.5, 0.5])
    b = -0.7
    tmp = np.sum(w * x) + b
    if tmp <= 0:
        return 0
    else:
        return 1
```

3-1. 퍼셉트론에서 신경망으로..

자세하게 들여다 보면 **입력과 가중치 신호를 조합한 결과** 그리고.. 그 값을 가지고 **출력값으로 변환하는 계산**

$$y = \begin{cases} 0 & (w1x1 + w2x2 + b \leq 0) \\ 1 & (w1x1 + w2x2 + b > 0) \end{cases}$$

```python
def AND(x1, x2):
    x = np.array([x1, x2])
    w = np.array([0.5, 0.5])
    b = -0.7
    tmp = np.sum(w * x) + b
    if tmp <= 0:
        return 0
    else:
        return 1
```

3-2. 활성화 함수(Activation Function)

출력 값으로 변환하는 계산! 사실 이미 사용하던 것….!

3-2. 활성화 함수(Activation Function)

활성화 함수(Activation Function)의 등장!

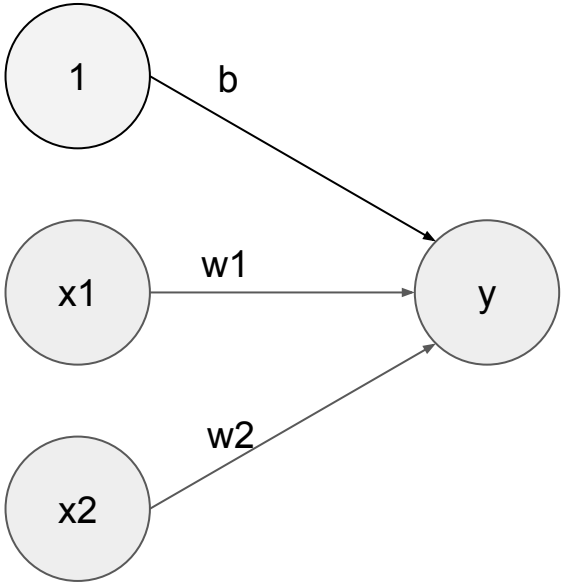

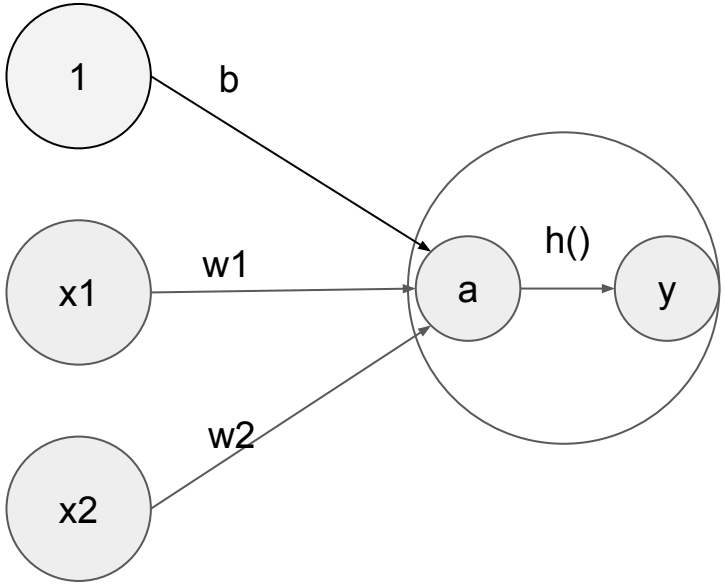

3-2. 활성화 함수(Activation Function)

활성화 함수(Activation Function)의 등장! (사실 이미 알던 것)

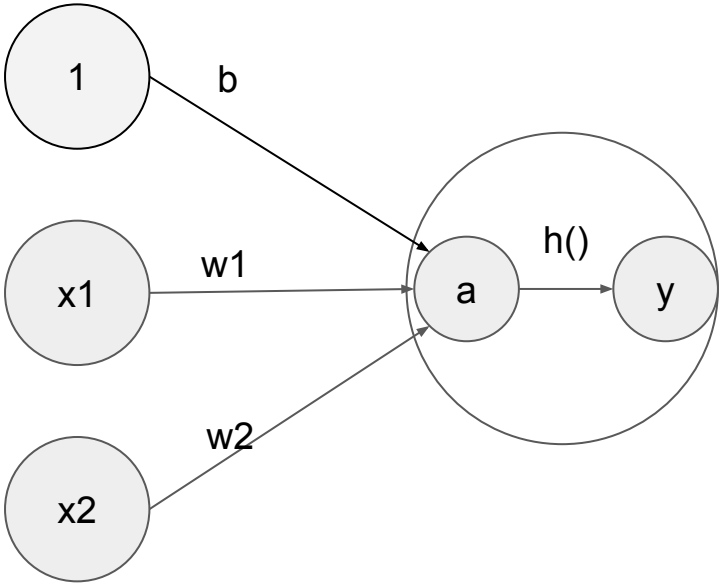

a: 입력과 가중치 신호를 조합한 결과(입력신호의 총합) 노드 == 뉴런

y: 활성화 함수 h()를 통과하여 변환된 결과 노드 == 뉴런

3-2. 활성화 함수(Activation Function)

계단 함수

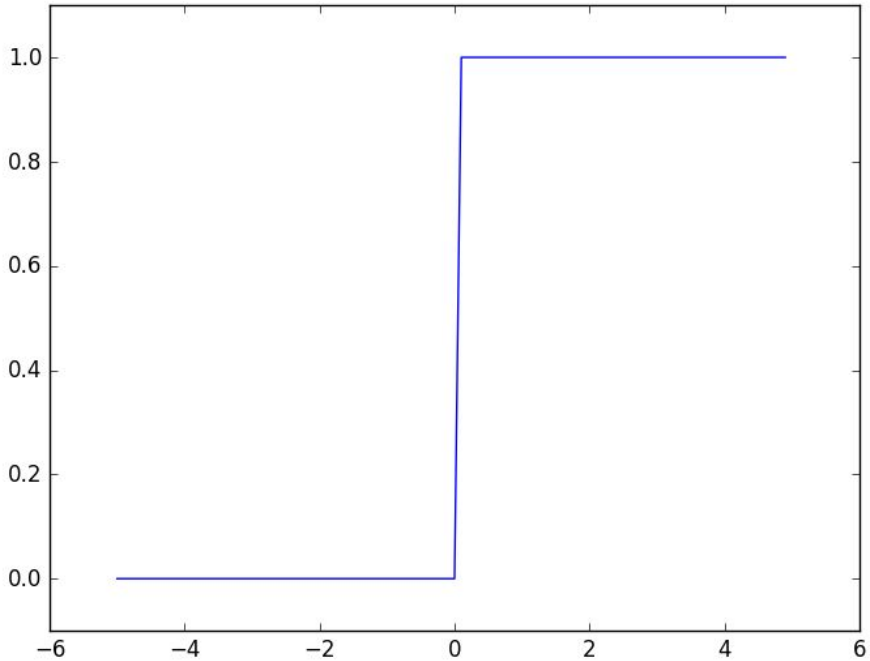


```
def step_function(x):
    if x > 0:
        return 1
    else
        return 0
```

3-2. 활성화 함수(Activation Function)

시그모이드(sigmoid) 함수

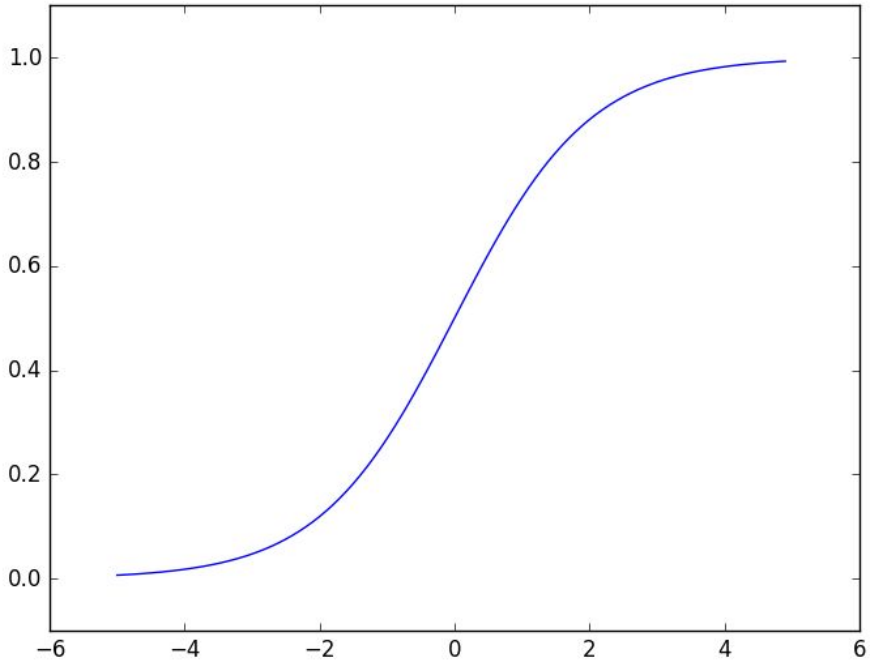


```
def sigmoid(x):
    return 1 / (1 + np.exp(-x))
```

3-2. 활성화 함수(Activation Function)

ReLU 함수

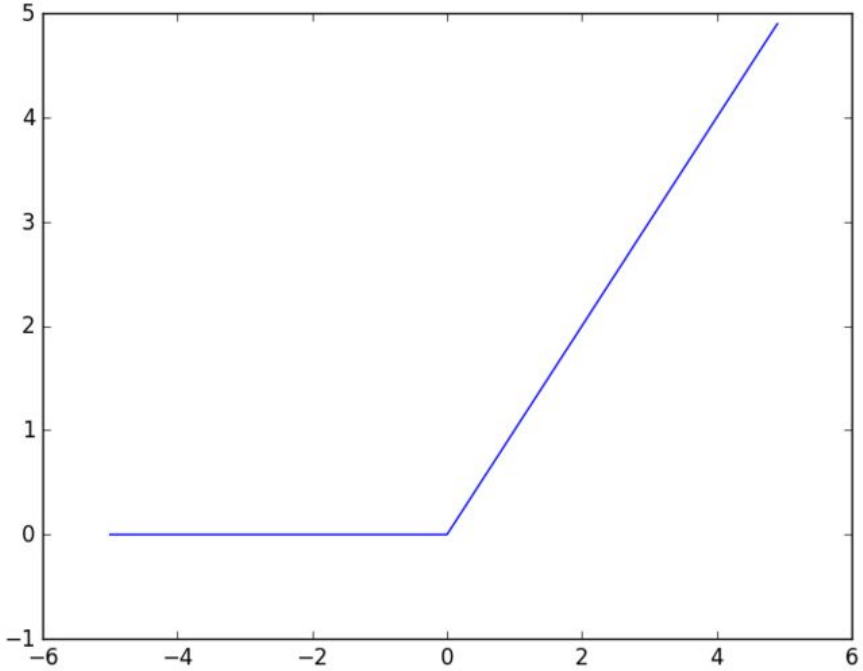


```
def relu(x):
    return np.maxinum(0, x)
```

3-2. 활성화 함수(Activation Function)

각자 다른 쓰임새가 있으나 요즘에는 **ReLU**를 많이 사용한다.

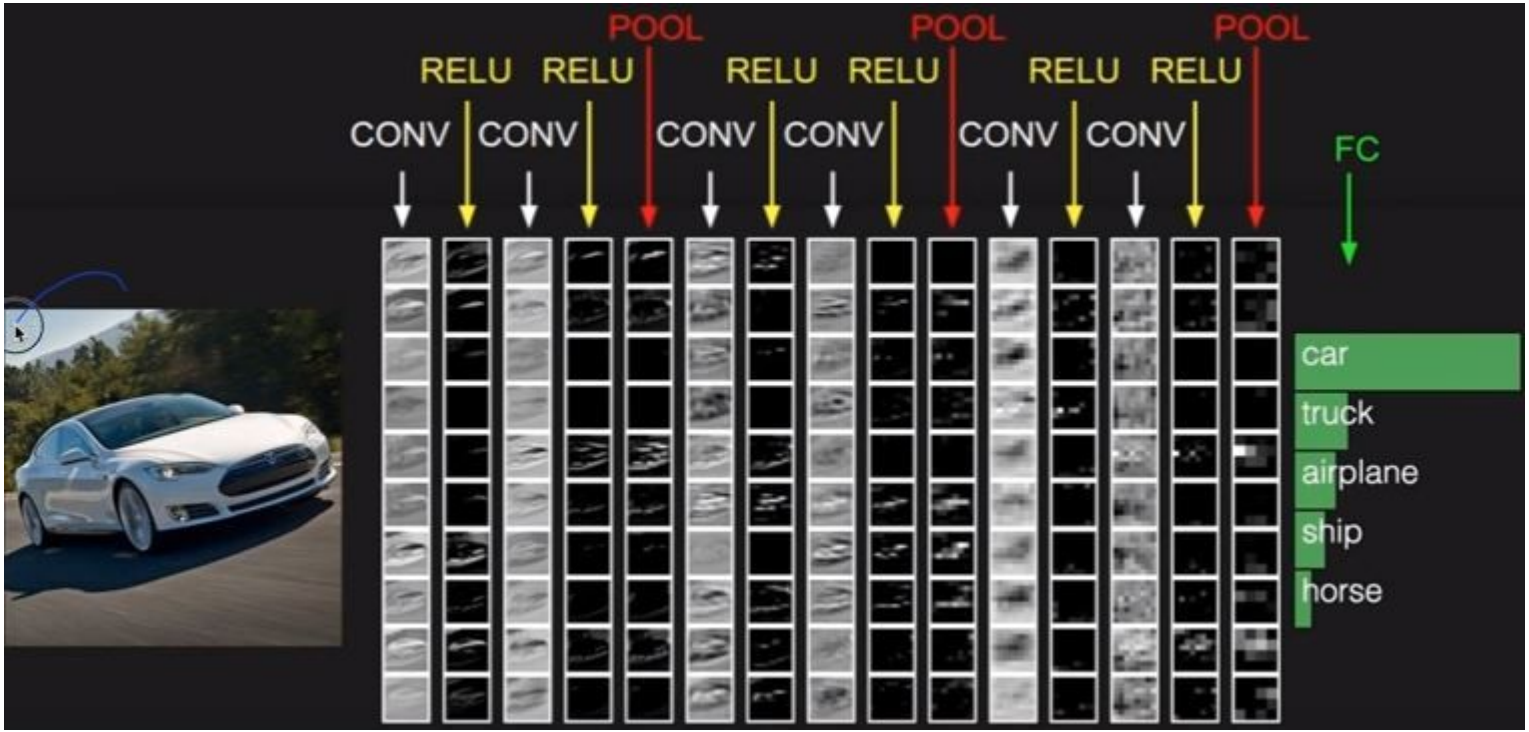

3-3. 다차원 배열의 계산

신경망을 효율적으로 구현하기 위하여.. 잠시 다차원 배열 설명을 하겠습니다.

3-3. 다차원 배열의 계산

다차원 배열

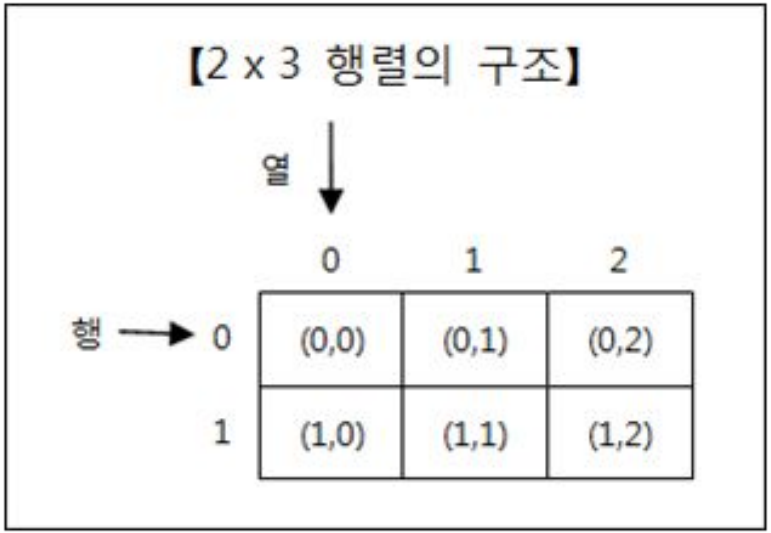

3-3. 다차원 배열의 계산

행렬의 내적 (행렬 곱) - 연산 방법

그림 3-11 행렬의 내적 계산 방법

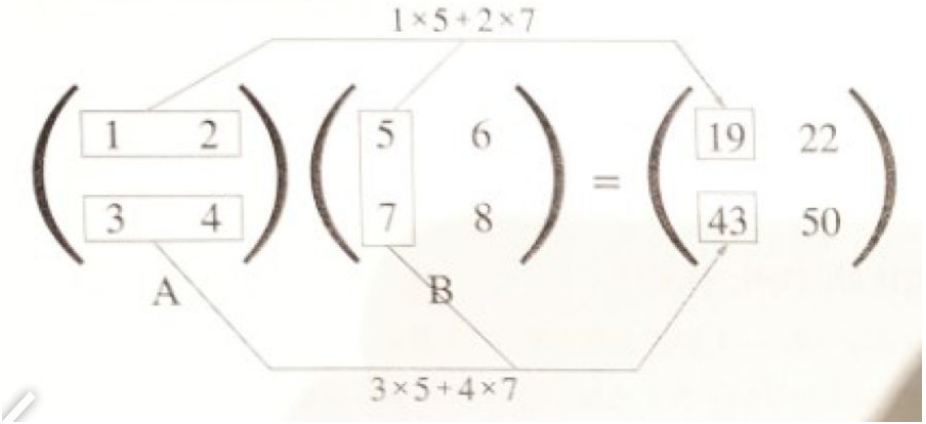


```python
import numpy as np

A = np.array([[1, 2],
              [3, 4]])

B = np.array([[5, 6],
              [7, 8]])

r = np.dot(A, B)

print(r)
```

```
[[19 22]
 [43 50]]
```

3-3. 다차원 배열의 계산

행렬의 내적 (행렬 곱) - 대응하는 차원의 원소 수가 같아야 곱이 가능하다

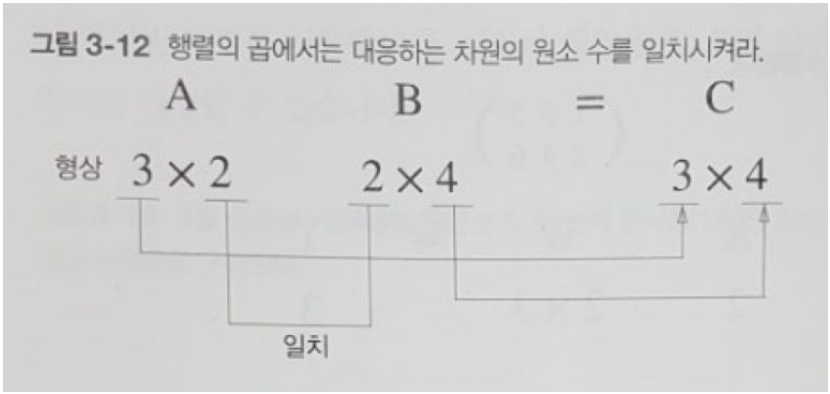

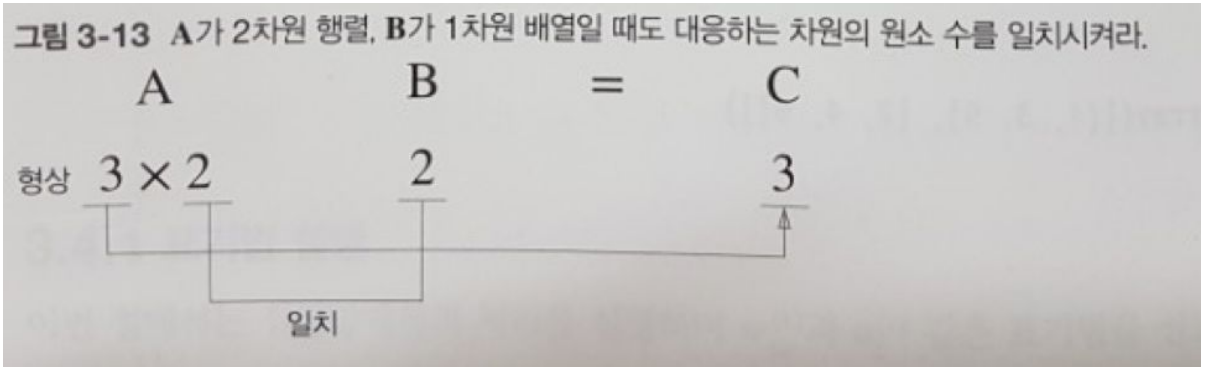

3-3. 다차원 배열의 계산

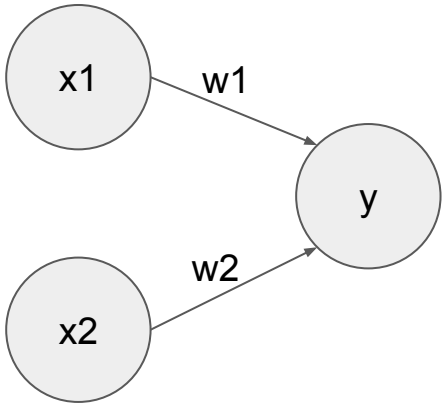

$$x1w1 + x2w2 = y$$

$$(x1\ x2)\begin{bmatrix} w1 \\ w2 \end{bmatrix} = (y)$$

3-3. 다차원 배열의 계산

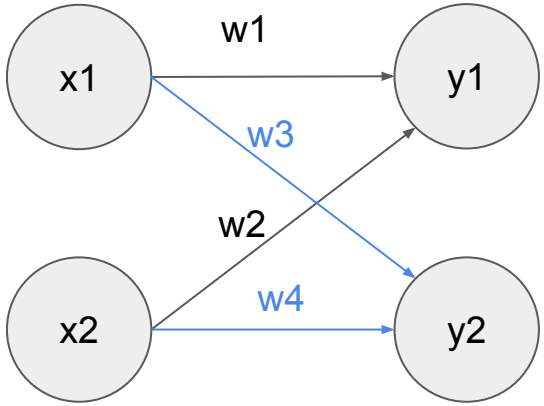

$$x1w1 + x2w2 = y1$$
$$x1w3 + x2w4 = y2$$

$$(x1\ x2)\begin{bmatrix} w1 & w3 \\ w2 & w4 \end{bmatrix} = (y1, y2)$$

3-3. 다차원 배열의 계산

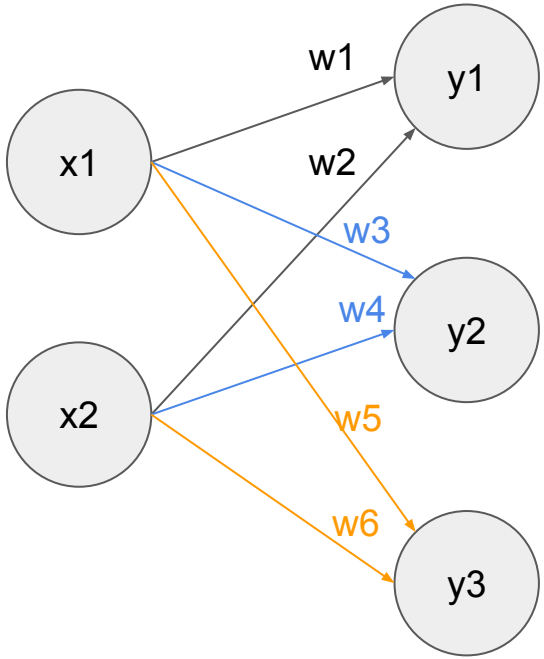

$$x1w1 + x2w2 = y1$$
$$x1w3 + x2w4 = y2$$
$$x1w5 + x2w5 = y2$$

$$(x1\ x2)\begin{bmatrix} w1 & w3 & w5 \\ w2 & w4 & w6 \end{bmatrix} = (y1, y2, y3)$$

3-3. 다차원 배열의 계산

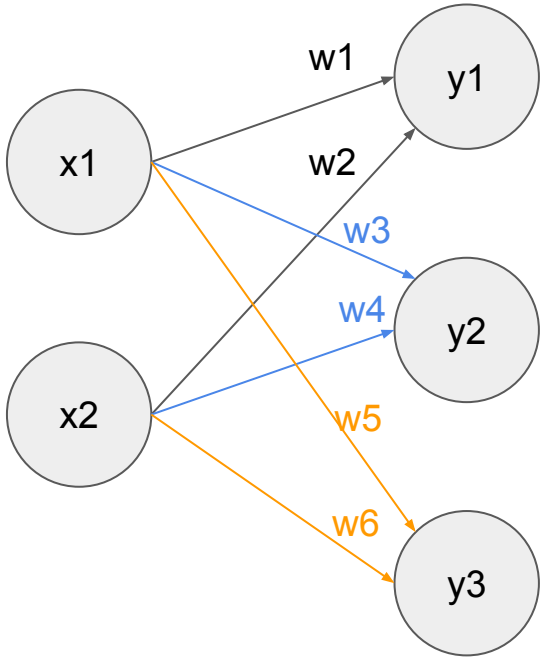

$$(x1\ x2)\begin{bmatrix}1 & 3 & 5\\ 2 & 4 & 6\end{bmatrix} = (y1, y2, y3)$$

```
X = np.array([1, 2])

W = np.array([[1, 3, 5],
              [2, 4, 6]])

Y  = np.dot(X, W)

print(Y)
```

```
[ 5 11 17]
```

3-3. 다차원 배열의 계산

신경망을 효율적으로 구현할 수 있고,

입력값 수 출력값 수 그리고 필요한 가중치(W) 등을 유연하게 조정할 수 있다.

-> 다중 레이어를 갖는 Deep Learning 에서 매우 유용!

3-4. 3층 신경망 구현하기

다시 돌아와서..

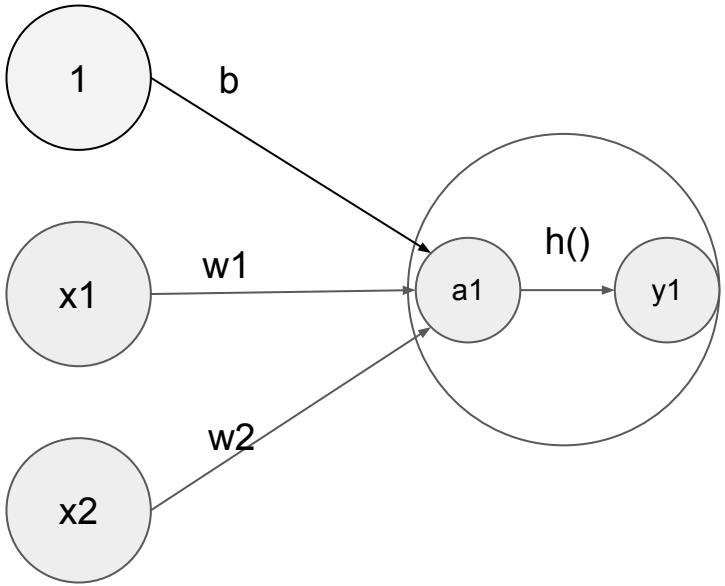

3-4. 3층 신경망 구현하기

다시 돌아와서.. Neural Network Layer 예제

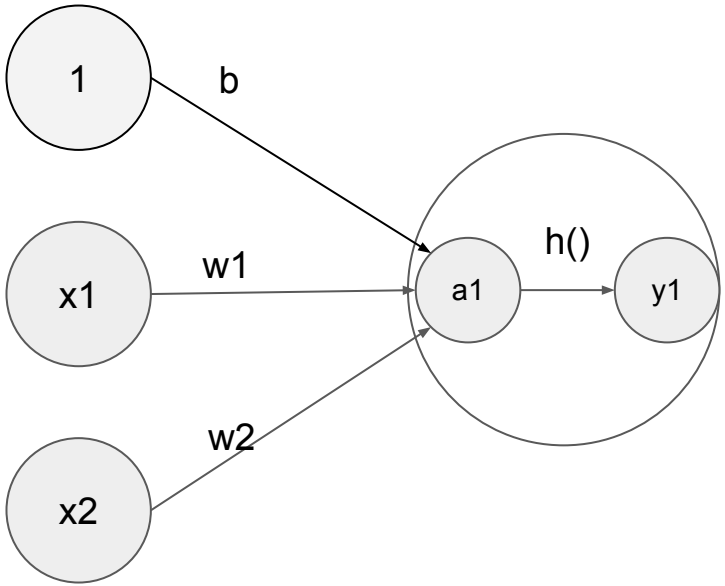

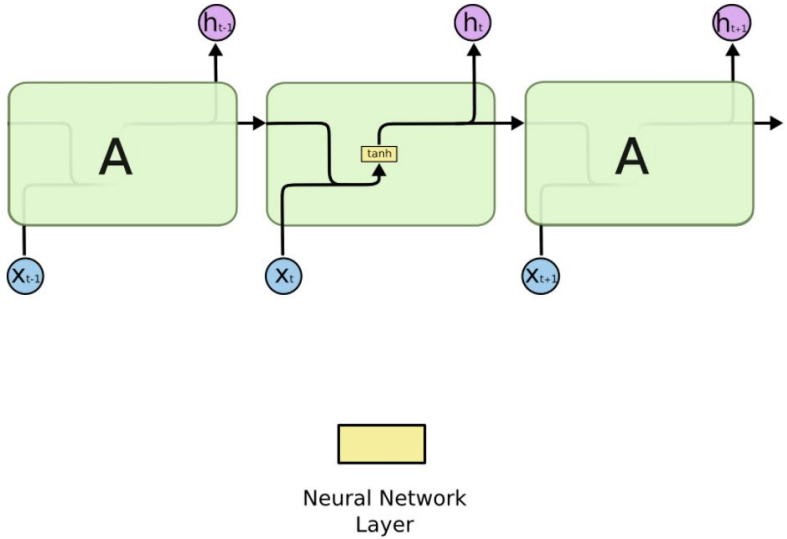

$$H_t = \tanh([H_{t-1}, X_t] \cdot W + B)$$

3-4. 3층 신경망 구현하기

헷갈릴 수도 있다! 앞으로 구현할 신경망에서..

- 입력(X)은 우리가 제공할 값
- 출력(Y)은 신경망에서 나올 결과 값
- 가중치(W)와 편향(B)는 이미 학습되어 주어진 값

-> 자동으로 학습하는 방법은 나중에!

3-4. 3층 신경망 구현하기

입력층에서 1층으로 신호 전달

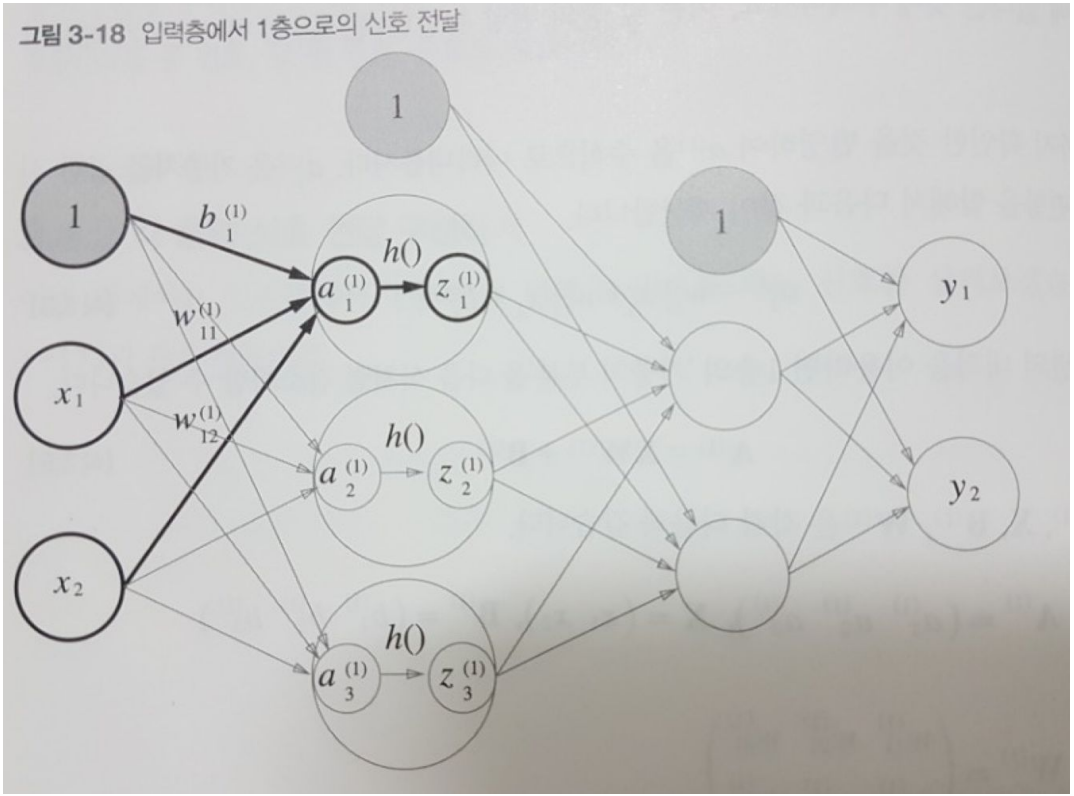

3-4. 3층 신경망 구현하기

1층에서 2층으로의 신호 전달

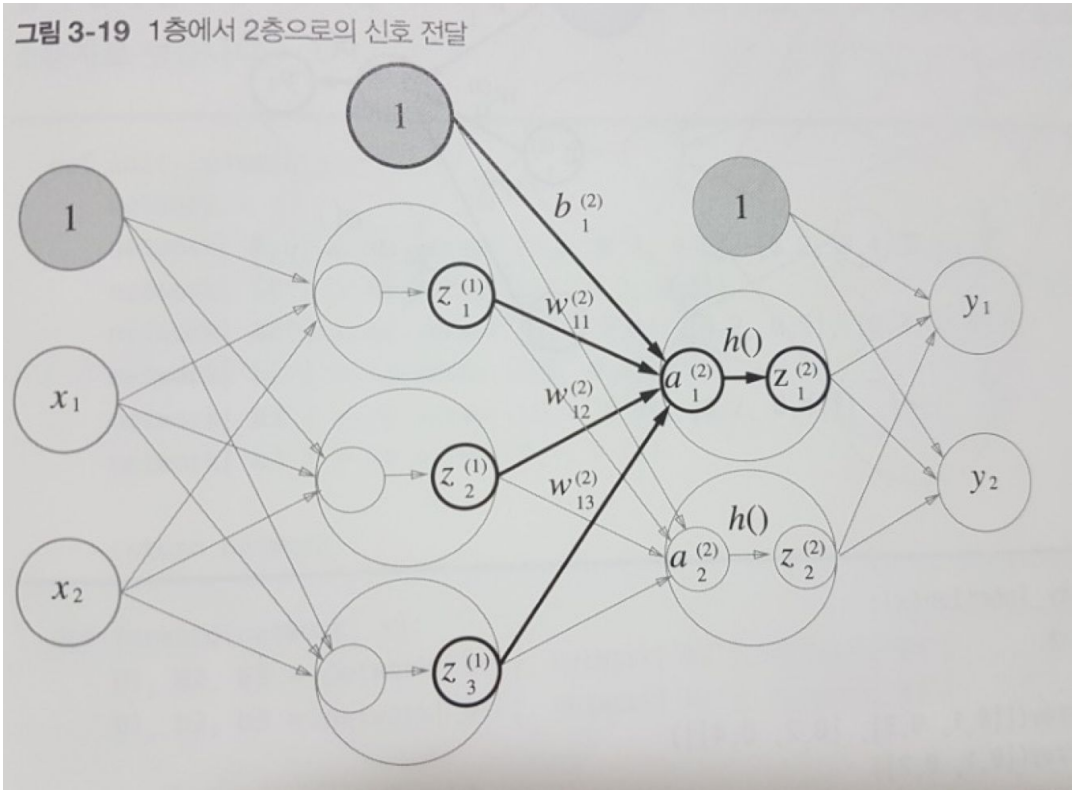

그림 3-19 1층에서 2층으로의 신호 전달

3-4. 3층 신경망 구현하기

2층에서 출력층으로의 신호 전달

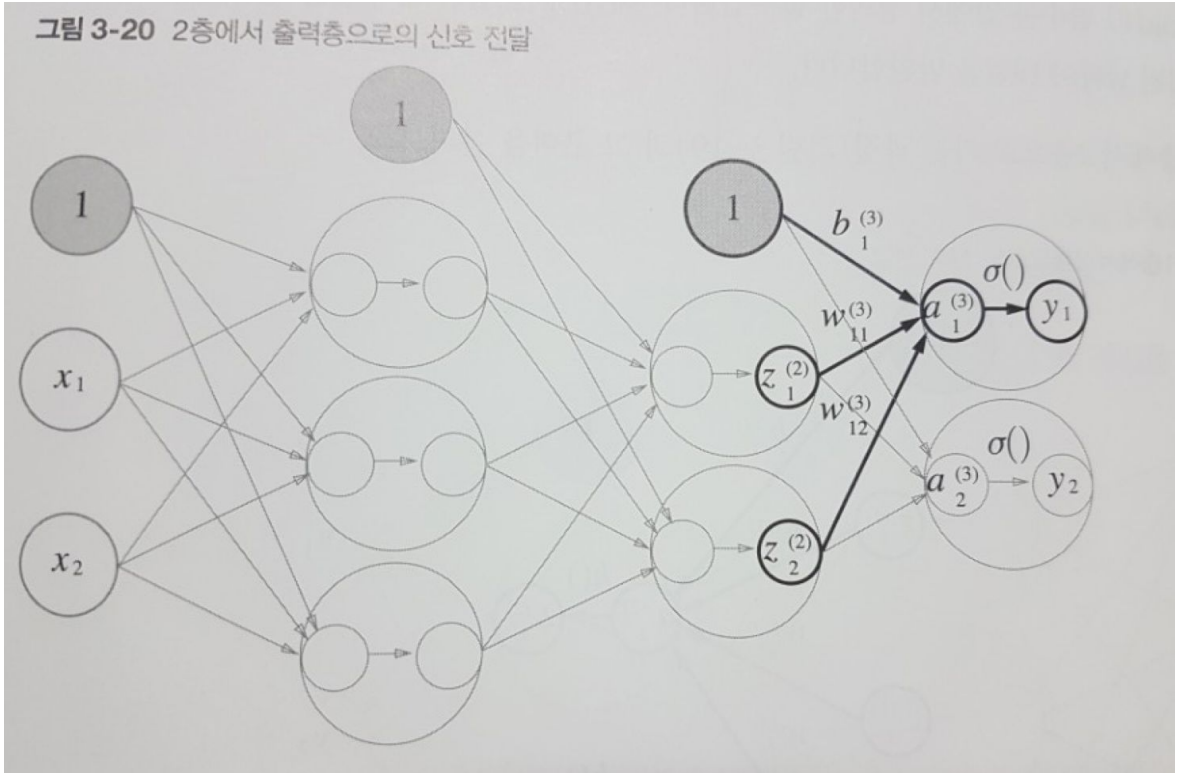

3-4. 3층 신경망 구현하기

순수 코코코딩 으로 3층짜리 신경망을 구현해보자

```python
import numpy as np

def sigmoid(x):
    return 1 / (1 + np.exp(-x))

def identity_function(x):
    return x

def init_network():
    network = {}
    network['W1'] = np.array([[0.1, 0.3, 0.5], [0.2, 0.4, 0.6]])
    network['b1'] = np.array([0.1, 0.2, 0.3])
    network['W2'] = np.array([[0.1, 0.4], [0.2, 0.5], [0.3, 0.6]])
    network['b2'] = np.array([0.1, 0.2])
    network['W3'] = np.array([[0.1, 0.3], [0.2, 0.4]])
    network['b3'] = np.array([0.1, 0.2])

    return network
```

```python
def forward(network, x):
    W1, W2, W3 = network['W1'], network['W2'], network['W3']
    b1, b2, b3 = network['b1'], network['b2'], network['b3']

    a1 = np.dot(x, W1) + b1
    z1 = sigmoid(a1)
    a2 = np.dot(z1, W2) + b2
    z2 = sigmoid(a2)
    a3 = np.dot(z2, W3) + b3
    y = identity_function(a3)

    return y

network = init_network()
x = np.array([1.0, 0.5])
y = forward(network, x)

print(y)
```

```
[ 0.31682708  0.69627909]
```

3-5. 그렇다면 마지막 출력층은?

값을 그대로 내보내는 항등함수!

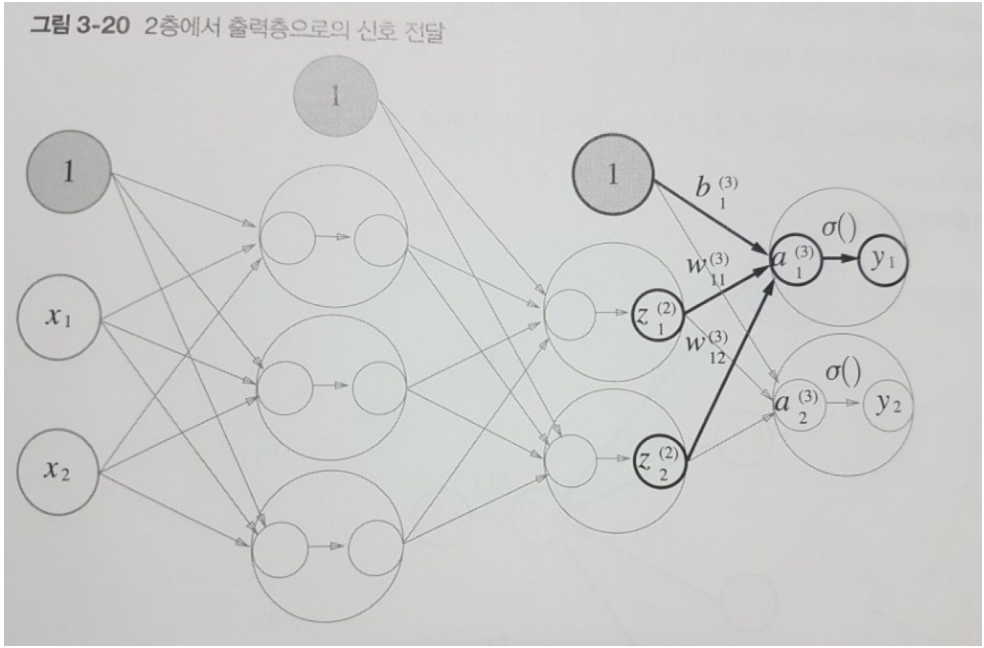

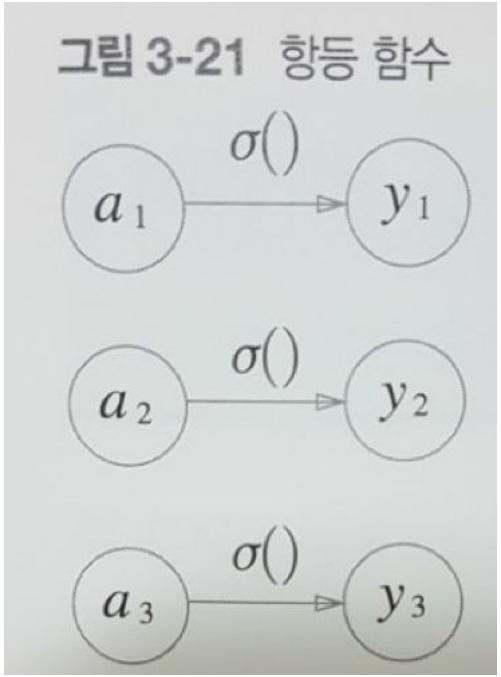

3-5. 그렇다면 마지막 출력층은?

모든 출력의 합을 1로 만드는!! 소프트맥스(softmax)!

그림 3-22 소프트맥스 함수

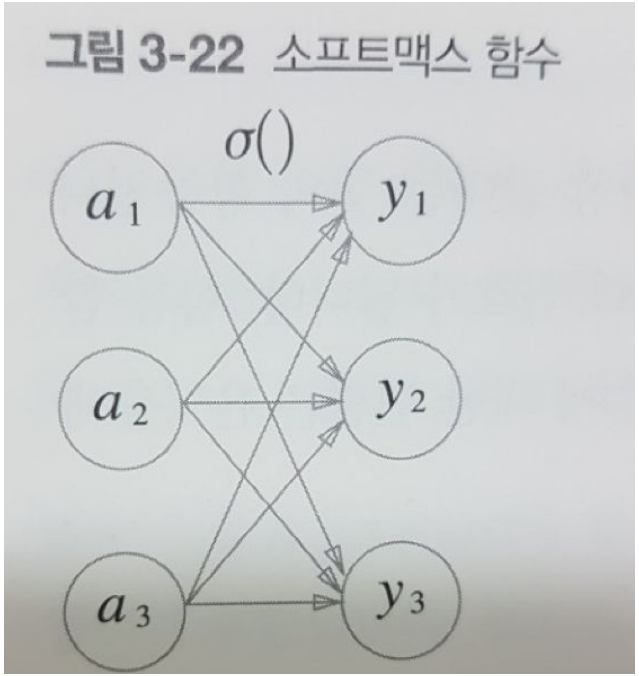

3-5. 그렇다면 마지막 출력층은?

모든 출력의 합을 1로 만드는!! 소프트맥스(softmax)!

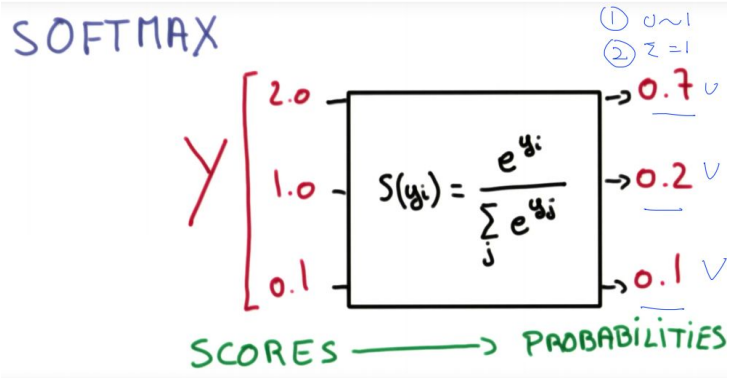


```python
import numpy as np

def softmax(a):
    c = np.max(a)
    exp_a = np.exp(a - c)
    sum_exp_a = np.sum(exp_a)
    y = exp_a / sum_exp_a

    return y

a = np.array([0.3, 2.9, 4.0])
y = sofmax(a)

print(y)
print(np.sum(y))
```

```
[ 0.01821127  0.24519181  0.73659691]
1.0
```

3-3. 다차원 배열의 계산

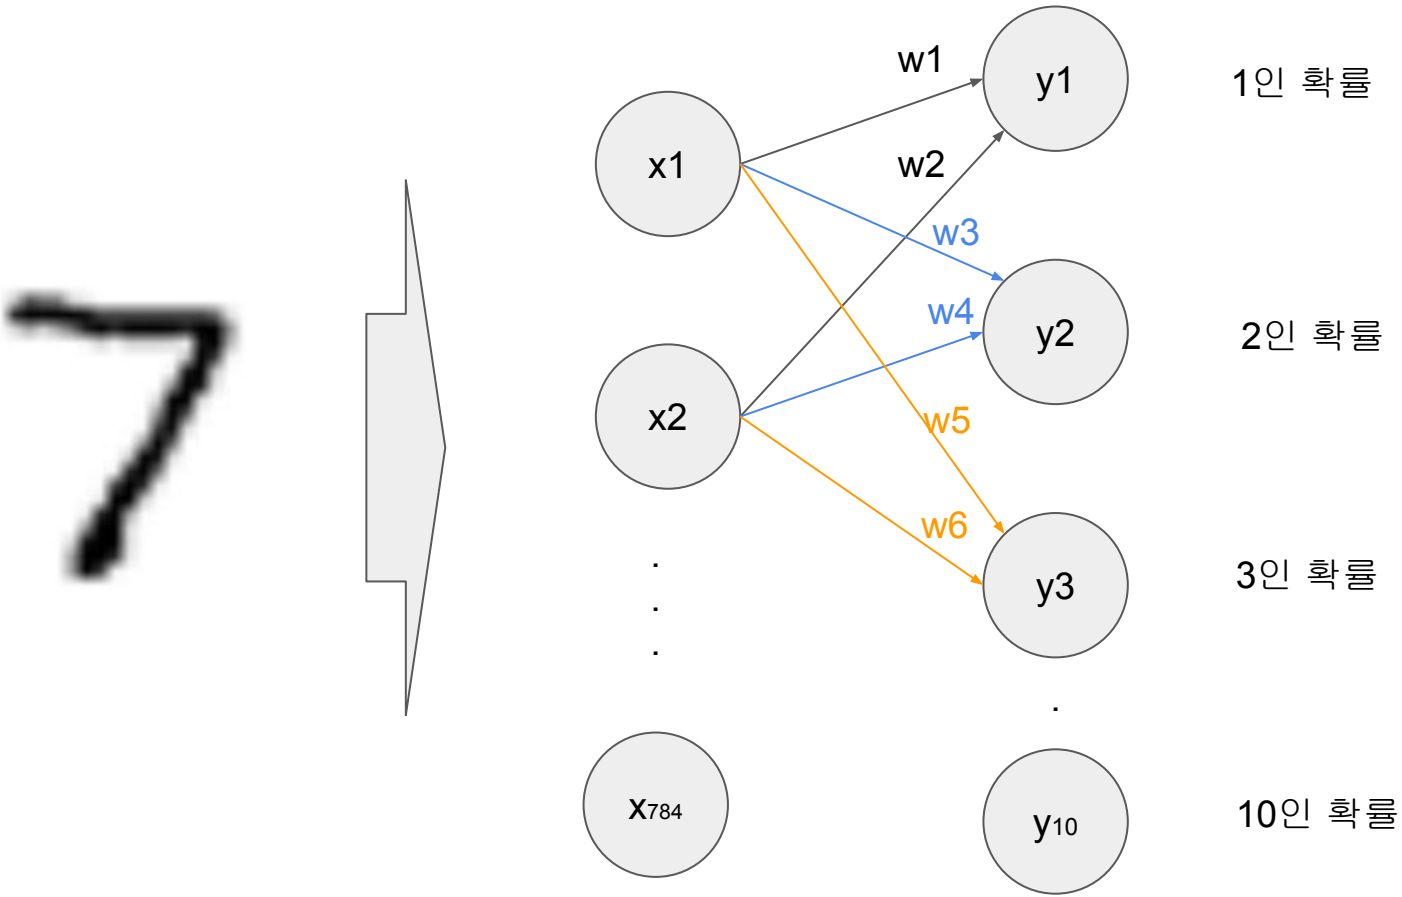

3-5. 그렇다면 마지막 출력층은?

+ 출력층의 뉴런 수는 어떻게 정해지는가? classification(분류) 과 관련

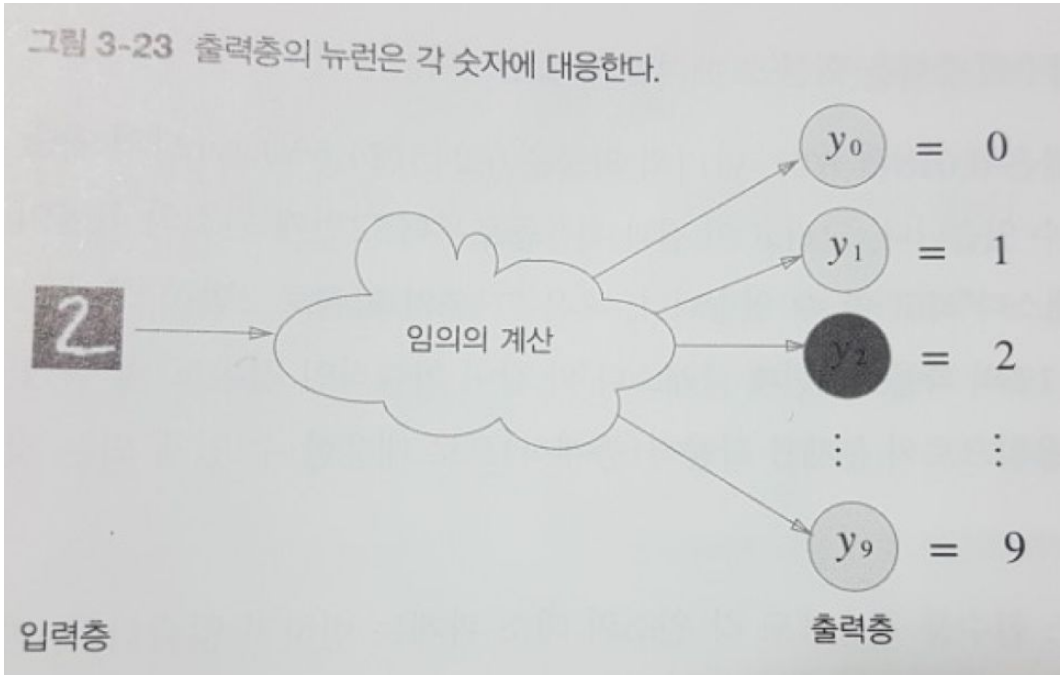

3-5. 그렇다면 마지막 출력층은?

손글씨를 인식해보자 : MNIST